Testowanie Generatorów Liczb Pseudolosowych

Dobrosława Hetmańczyk

2 listopada 2025

Spis treści

1 Wstęp **2**

2 Generatory liczb pseudolosowych **2**

3 Mersenne Twister **2**

4 XorShift128 **3**

5 Testy statystyczne **3**

6 Runs Test **3**

7 Dobór parametrów **3**
7.1 Generator LCG 4
7.2 Generator RC4 4
7.3 Generator Mersenne Twister 4
7.4 Generator Xorshift128 4

8 Porównanie wybranych generatorów **4**
8.1 Analiza histogramów wartości 4
8.2 Analiza testów statystycznych 6
8.3 Analiza map ciepła 7

9 Second-level testing **9**

10 Podsumowanie wyników **10**

1 Wstęp

W symulacjach Monte Carlo kluczowe znaczenie ma wybór odpowiedniego generatora liczb pseudolosowych, jako że nie każdy z nich zapewnia pożądane własności statystyczne, takie jak jednorodność, niezależność czy brak powtarzających się wzorców. W celu oceny jakości działania generatorów wykorzystuje się zestandaryzowane testy empiryczne, które pozwalają określić ich zgodność z rozkładem jednostajnym.

Celem tego projektu jest porównanie czterech generatorów liczb pseudolosowych pod kątem ich właściwości statystycznych oraz ocena jakości generowanych ciągów na podstawie uzyskanych statystyk testowych i odpowiadających im p-wartości. Analiza ma na celu ustalenie, które z badanych generatorów można uznać za najbardziej losowe i odpowiednie do zastosowań w symulacjach.

2 Generatory liczb pseudolosowych

Do tego projektu wybrano cztery następujące generatory liczb pseudolosowych:

- Liniowy generator kongruencyjny (LCG)
- RC4
- Mersenne Twister
- XorShift128

3 Mersenne Twister

Generator Mersenne Twister został opracowany w celu przezwyciężenia ograniczeń klasycznych generatorów, takich jak LCG, zapewniając bardzo długi okres, równomierny rozkład oraz wysoką wydajność obliczeniową. Działa w oparciu o tablicę stanu zawierającą 624 liczby 32-bitowe, inicjalizowaną ziarnem według wzoru: jeśli $MT[0] = \text{ziarno}$, to dla $i = 1..623$:

$$MT[i] = (69069 \cdot MT[i-1]) \bmod 2^{32}$$

Aby wygenerować nową liczbę, MT łączy dwa elementy tablicy stanu przy użyciu operacji bitowych (XOR i przesunięć bitowych). Najpierw łączymy najbardziej znaczący bit $MT[mti]$ z dolnymi 31 bitami $MT[mti+1]$:

$$y = (MT[mti] \ \& \ 0x80000000) \mid (MT[(mti+1) \bmod 624] \ \& \ 0x7FFFFFFF)$$

$MT[mti] \ \& \ 0x80000000$ wyodrębnia najbardziej znaczący bit (MSB) bieżącego elementu. $MT[(mti+1) \bmod 624] \ \& \ 0x7FFFFFFF$ wyodrębnia dolne 31 bitów następnego elementu. Operacja bitowa OR ($|$) łączy je w jedną 32-bitową liczbę y. Następnie stosowana jest transformacja sprzężenia zwrotnego, która aktualizuje tablicę stanu i zapewnia długi okres generatora:

$$MT[mti] = MT[(mti+397) \bmod 624] \ \oplus \ (y \gg 1) \ \oplus \ MA[y \ \& \ 1]$$

$MT[(mti+397) \bmod 624]$ wybiera element oddalony o 397 pozycji. $(y \gg 1)$ przesuwa y w prawo o 1 bit, mieszając bity wyższe i niższe. $MA[y \ \& \ 1]$ stosuje stałą magiczną zależną od najmniej znaczącego bitu y:

$$MA[0] = 0, \quad MA[1] = 0x9908B0DF$$

$\oplus$ oznacza operację bitową XOR, która łączy wszystkie trzy składniki. Ostatecznie surowy wynik jest poddawany tzw. „temperowaniu” — serii operacji bitowych mających na celu poprawę właściwości statystycznych i uzyskanie bardziej jednorodnego rozkładu:

$$\begin{aligned}
y &\leftarrow y \ \oplus \ (y \gg 11) \\
y &\leftarrow y \ \oplus \ ((y \ll 7) \ \& \ 0x9D2C5680) \\
y &\leftarrow y \ \oplus \ ((y \ll 15) \ \& \ 0xEFC60000) \\
y &\leftarrow y \ \oplus \ (y \gg 18)
\end{aligned}$$

Generator zwraca 32-bitową liczbę pseudolosową.

4 XorShift128

Generator XorShift128 generuje 32-bitowe liczby za pomocą operacji bitowych (XOR i przesunięć). Charakteryzuje się długim okresem równym $2^{128}-1$, co zapewnia niezależność i jednorodność wyników. Generator przechowuje cztery 32-bitowe zmienne: x, y, z, w. Niech a, b, c będą stałymi (zazwyczaj $a = 11$, $b = 19$, $c = 8$). Algorytm wygląda następująco:

$$
\begin{aligned}
t &= x \oplus (x \ll a) \\
x &\leftarrow y \\
y &\leftarrow z \\
z &\leftarrow w \\
w &\leftarrow w \oplus (w \gg b) \oplus (t \oplus (t \gg c))
\end{aligned}
$$

Generator zwraca w jako kolejną liczbę pseudolosową.

Do działania wymagane są jedynie cztery 32-bitowe zmienne stanu, co sprawia, że XorShift128 jest niezwykle szybki.

5 Testy statystyczne

Do tego projektu wybrano cztery następujące testy statystyczne:

- Test χ^2
- Frequency Monobit Test
- Birthday Spacing Test
- Runs Test

6 Runs Test

Niech $X_1, X_2, \ldots, X_n$ będzie ciągiem liczb wygenerowanych przez generator liczb pseudolosowych. Dla ciągu binarnego zdefiniujmy:

$$
Y_i = \begin{cases} 1 & \text{jeśli } X_i > \text{średnia lub mediana,} \\ 0 & \text{w przeciwnym razie.} \end{cases}
$$

Niech R oznacza całkowitą liczbę serii (ciągu kolejnych, identycznych elementów w badanej sekwencji) w ciągu $Y_1, \ldots, Y_n$. Hipoteza zerowa H_0 zakłada, że rozkład ciagu jest losowy (niezależny i równomierny).

Wartość oczekiwana liczby serii oraz jej wariancja są dane wzorami:

$$
E(R) = \frac{2n_1n_0}{n} + 1, \quad \mathrm{Var}(R) = \frac{2n_1n_0(2n_1n_0 - n)}{n^2(n-1)},
$$

gdzie n_1 to liczba jedynek, n_0 to liczba zer, a $n = n_1 + n_0$. Statystyka testowa ma postać:

$$
Z = \frac{R - E(R)}{\sqrt{\mathrm{Var}(R)}} \sim N(0,1) \text{ przy } H_0.
$$

Runs test jest czuły na zależności w kolejności elementów ciągu i może być stosowany zarówno do sekwencji binarnych, jak i rzeczywistych.

7 Dobór parametrów

Aby uzyskać satysfakcjonujące nas wyniki, parametry każdego PRNG muszą być starannie dobrane.

7.1 Generator LCG

W przypadku generatora LCG wykorzystano stałe $m = 2^{32}, a = 1664525, c = 1013904223$. Tak dobrane parametry gwarantują pełny okres równy 2^{32}, co oznacza, że generator wytwarza maksymalnie długi ciąg liczb pseudolosowych bez powtórzeń. Wartość mnożnika a zapewnia równomierne rozproszenie liczb oraz minimalizuje korelacje między kolejnymi wartościami. Stan początkowy ustalono na $X_0 = 1$, co pozwala uzyskać pełną długość sekwencji o odpowiednich właściwościach statystycznych.

7.2 Generator RC4

Generator RC4 został skonfigurowany z 256-bajtową tablicą stanu oraz 5-bajtowym kluczem $K = [1, 2, 3, 4, 5]$. Pomimo niewielkiej długości klucza, jego odpowiedni dobór umożliwia uzyskanie dobrze wymieszanego stanu początkowego w procesie inicjalizacji (KSA).

7.3 Generator Mersenne Twister

Dla generatora Mersenne Twister wykorzystano wariant MT19937 z ziarnem początkowym seed = 5678. Ustalony seed umożliwia powtarzalność wyników w procesie testowania.

7.4 Generator Xorshift128

W przypadku generatora Xorshift128 przyjęto parametry $(a, b, c) = (11, 8, 19)$. Generator ten utrzymuje 128-bitowy stan wewnętrzny reprezentowany jako czteroelementowy wektor $[x, y, z, w]$, który w każdej iteracji modyfikowany jest za pomocą operacji XOR oraz przesunięć bitowych. Przyjęty stan początkowy $[1, 1, 1, 1]$ zapewnia brak zerowych wartości, co eliminuje ryzyko generowania trywialnej sekwencji zer. Zastosowane parametry gwarantują maksymalny okres równy $2^{128} - 1$ oraz równomierność rozkładu wygenerowanych liczb.

8 Porównanie wybranych generatorów

8.1 Analiza histogramów wartości

Aby przeanalizować działanie wybranych generatorów, z każdego nich wygenerowano próbkę o rozmiarze 2^{12} i $5 * 10^4$. Uzyskane ciągi zobrazowano za pomocą histogramów, aby zbadać rozkład ich wartości.

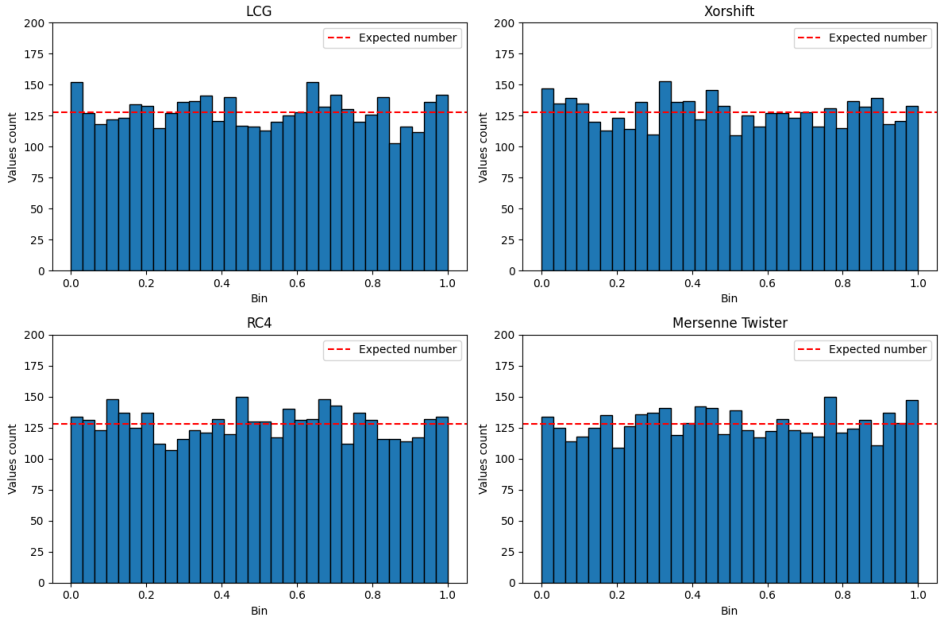

Rysunek 1: Histogramy wartości dla $n_1 = 2^{12}$

W powyższych histogramach przedział $[0, 1]$ został podzielony na $k = 32$ równych podprzedziałów, a dla każdego generatora wygenerowano $n = 2^{12}$ wartości. Przy założeniu idealnej jednorodności rozkładu każdy przedział powinien zawierać średnio $n/k = 4096/32 = 128$ wartości, co zostało oznaczone czerwoną przerywaną linią na każdym wykresie. Wysokość słupków reprezentuje rzeczywistą liczbę wartości przypadających na dany podprzedział, co umożliwia wizualną ocenę równomierności rozkładu.

Wybrana liczba przedziałów $k = 32$ wynika głównie z tego że, generator RC4 generuje bajty o maksymalnie 256 możliwych wartościach, dlatego ten wybór zapewnia porównanie wszystkich generatorów bez zniekształceń.

Ogólnie rzecz biorąc, wszystkie cztery generatory tworzą histogramy zgodne z oczekiwanym rozkładem jednostajnym. Niewielkie odchylenia od czerwonej linii są naturalne i wynikają z losowych fluktuacji próbkowania, szczególnie przy umiarkowanej liczebności próbki. Spośród testowanych generatorów, Mersenne Twister wydaje się być dość stabilny — wysokości słupków oscylują blisko wartości oczekiwanej. Rozkład wartości jest równomierny, a różnice między binami wynikają prawdopodobnie z losowej zmienności. Nie ma zauważalnych odchyleń od oczekiwanego kształtu. Takie zachowanie odzwierciedla bardzo dobre właściwości tego generatora oraz jego niezwykle długi okres $2^{19937} - 1$, co czyni go jednym z najbardziej niezawodnych statystycznie generatorów obecnie stosowanych.

Generator Xorshift również wykazuje dobrą jednorodność. Histogram jest wyrównany, a odchylenia od wartości oczekiwanej są niewielkie i mają charakter losowy. Nie ma oznak skupienia wartości w żadnym zakresie, co wskazuje na poprawne właściwości losowe.

Z kolei generator LCG wykazuje dość równomierny rozkład wartości, z jedynie drobnymi fluktuacjami w poszczególnych przedziałach, co sugeruje, że parametry zostały dobrze dobrane. RC4 również wykazuje jednorodność, jednak miejscami widoczne są nieco większe różnice między wysokościami słupków. Mimo to nie obserwuje się żadnych systematycznych trendów ani koncentracji, więc rozkład można uznać za zgodny z jednostajnym.

Mimo tych różnic, żaden z analizowanych generatorów nie wykazuje silnego grupowania ani pustych przedziałów, co wskazuje, że wszystkie przechodzą wizualny test jednorodności dla przyjętej liczebności próbki. Uzyskane wyniki potwierdzają, że na poziomie rozkładu pojedynczych wartości badane generatory pseudolosowe generują dane dobrze przybliżające rozkład jednostajny na przedziale $[0, 1]$.

Aby uzyskać lepsze porównanie, z każdego PRNG wygenerowano próbkę o rozmiarze $n = 5 * 10^4$.

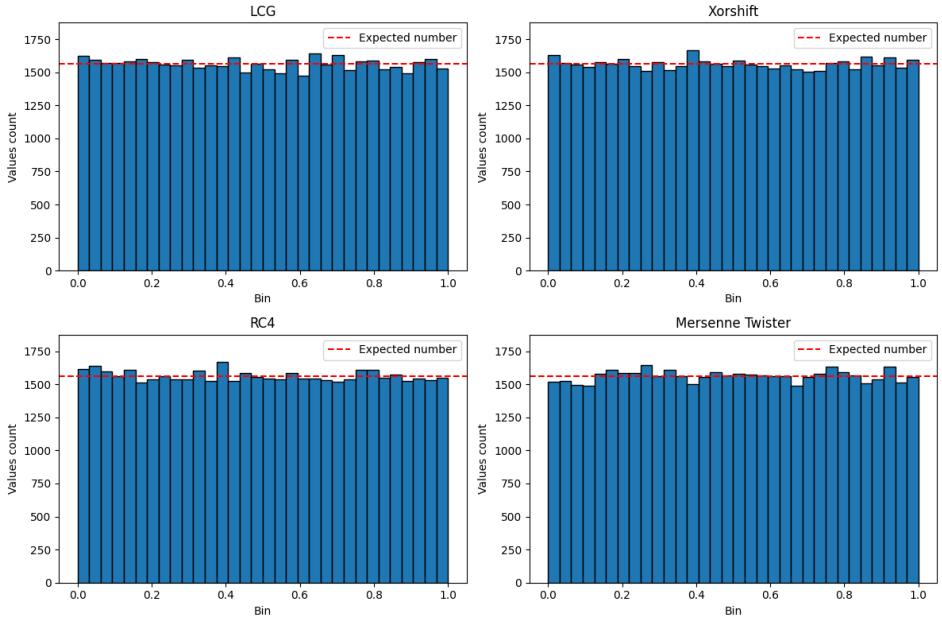

Rysunek 2: Histogramy wartości dla $n = 5 * 10^4$

Na pierwszy rzut oka wszystkie cztery histogramy wykazują stosunkowo jednolity rozkład, co pokazuje, że każdy z analizowanych generatorów generuje liczby dobrze przybliżające rozkład jednostajny. Czerwona linia widoczna na każdym wykresie odpowiada oczekiwanej liczbie wartości w danym prze-

dziale przy założeniu hipotezy zerowej o idealnej jednorodności rozkładu. Wszystkie generatory wykazują bardzo zbliżone zachowanie, generując rozkłady praktycznie nieodróżnialne od jednostajnego.

Podsumowując, analiza histogramów potwierdza, że wszystkie badane generatory generują dane zgodne z rozkładem jednostajnym, co świadczy o ich poprawnym zachowaniu pod względem statystycznym. Można również zauważyć, że wraz ze wzrostem liczby wygenerowanych próbek rozkład wartości staje się coraz bardziej równomierny, a różnice między poszczególnymi przedziałami maleją. Oznacza to, że dla większych prób losowość generatorów jest lepiej widoczna, a ich wyniki coraz dokładniej odwzorowują rozkład jednostajny.

8.2 Analiza testów statystycznych

Aby potwierdzić wstępne obserwacje, wybrane generatory liczb pseudolosowych zostaną ocenione za pomocą czterech, opisanych wcześniej, testów statystycznych. We wszystkich procedurach statystycznych stosowanych względem PRNG, ogólne hipotezy można sformułować następująco:

$\mathbf{H_0}$: Generowany ciąg jest niezależny i ma rozkład jednostajny na przedziale $[0, 1]$,

$\mathbf{H_1}$: Generowany ciąg nie jest niezależny lub nie ma rozkładu jednostajnego na przedziale $[0, 1]$.

Chociaż hipoteza zerowa H_0 ogólnie rzecz biorąc jest taka sama dla wszystkich testów, poszczególne metody badają różne aspekty losowości i niezależności danych.

Test χ^2 ocenia jednorodność rozkładu wartości, sprawdzając, czy wszystkie podprzedziały z zakresu $[0, 1]$ są podobnie wypełnione. Monobit Test analizuje równowagę bitów, weryfikując, czy liczby zer i jedynek występują z przybliżoną częstotliwością. Runs Test bada niezależność i obecność ewentualnych struktur w sekwencji bitowej, sprawdzając, czy długości kolejnych serii identycznych bitów są zgodne z zachowaniem losowym. Z kolei Birthday Spacing test koncentruje się na analizie kolizji i regularności odstępów między wartościami, oceniając, czy powtarzające się różnice występują z częstotliwością oczekiwaną dla modelu Poissona.

Tabela 1: Porównanie wartości p dla różnych testów statystycznych

Generator	**Chi-square**	**Runs**	**Monobit**	**Birthday Spacing**
LCG	0.333198	0.742790	0.731034	0.371163
Xorshift128	0.497997	0.184085	0.110992	0.008132
RC4	0.435831	0.742048	0.802587	—
MT19937	0.704695	0.253970	0.925308	0.908422

Na potrzeby testów przyjmujemy poziom istotności $\alpha = 0.05$, co oznacza, że dla p-wartości > 0.05 dany generator pomyślnie przechodzi wskazany test - nie mamy podstaw do odrzucenia hipotezy zerowej zakładającej losowość i jednorodność rozkładu.

Ogólnie rzecz biorąc, wszystkie analizowane generatory wykazują zadowalające własności statystyczne w testach χ^2, Runs oraz Monobit. Generator Mersenne Twister uzyskał dość wysokie p-wartości we wszystkich testach, co potwierdza jego doskonałą jednorodność oraz niezależność rozkładu. Generator LCG również osiągnął dobre wyniki, choć jego liniowa struktura może prowadzić do pojawienia się korelacji w sekwencjach wielowymiarowych, które nie są wykrywalne w podstawowych testach jednowymiarowych. Generator Xorshift128 przeszedł większość testów pomyślnie, za wyjątkiem Birthday Spacing Test, co sugeruje pewne słabości w rozkładzie odstępów między wartościami. Generator RC4 uzyskał poprawne wyniki we wszystkich testach, które można było do niego zastosować.

Test Birthday Spacing nie został przeprowadzony dla RC4, ponieważ standardowy algorytm RC4 operuje na 8-bitowych wartościach, a więc możemy otrzymać 256 możliwych wyników. W Birthday Spacing Test konieczne jest określenie maksymalnej wartości m oraz obliczenie parametru $\lambda = \frac{n^3}{4m}$, gdzie n oznacza liczbę próbek. Ze względu na znacznie mniejszy zakres wyjściowy RC4 w porównaniu z pozostałymi generatorami (które operują na 2^{32} wartościach), parametr λ przyjmuje ogromne wartości, co prowadzi do degeneracji wyników ($p \approx 0$). A więc test nie ma sensu dla standardowej wersji RC4.

Podsumowując, uzyskane wyniki testów potwierdzają, że wszystkie analizowane generatory wykazują właściwości zgodne z założeniami losowości i rozkładu jednostajnego w zakresie badanej próbki, przy czym najlepsze rezultaty osiągnął generator Mersenne Twister.

Przeprowadźmy teraz te same testy dla $n = 5*10^4$. W przypadku ciągu o takim rozmiarze Birthday Spacing Test nie zadziała, ponieważ maksymalna wygenerowana liczba musi być około trzy razy większa niż n, co powoduje konieczność przeskalowania generatorów w celu wygenerowania tak dużych liczb. Ponadto większe n powodowałoby problem z Runs Test, ponieważ podczas obliczania wariacji może dojść do przepełnienia zmiennych (ang. *scalar overflow*), w wyniku czego test zwróci *NaN*.

Tabela 2: Porównanie wartości p dla różnych testów statystycznych

Generator	**Chi-square**	**Runs**	**Monobit**
LCG	0.304361	0.778137	0.194659
Xorshift128	0.648370	0.388065	0.371093
RC4	0.498684	0.698785	0.000677
MT19937	0.351961	0.225527	0.921625

Tak jak poprzednio generator Mersenne Twister ponownie wykazuje dobre właściwości statystyczne, uzyskując dość wysokie p-wartości we wszystkich testach, w szczególności w Monobit Test. Xorshift128 również osiąga całkiem dobre wyniki, utrzymując umiarkowane do wysokich wartości p, co wskazuje na dobry kompromis pomiędzy szybkością działania a jakością statystyczną generowanych liczb. LCG uzyskał akceptowalne, lecz nieco mniej stabilne wyniki - wykazuje on niższą jednorodność i losowość bitową w porównaniu z MT19937. Z kolei generator RC4 osiągnął wysokie p-wartości w testach χ^2 oraz Runs Test, lecz bardzo niską wartość $p = 0.0007$ w Monobit Test, co sugeruje potencjalną słabą równowagę na poziomie bitowym. Możliwą przyczyną tego zjawiska jest znany efekt biasu w algorytmie inicjalizacji klucza RC4, który może wpływać na równomierność bitów w początkowej części ciągu.

8.3 Analiza map ciepła

Aby jeszcze raz potwierdzić wstępne obserwacje dotyczące rozkładu i zależności pomiędzy analizowanymi zmiennymi, przeprowadzona została analiza map cieplnych (heatmap). Metoda ta pozwala w sposób wizualny ocenić strukturę danych, identyfikując obszary o zróżnicowanej intensywności wartości oraz potencjalne wzorce korelacji.

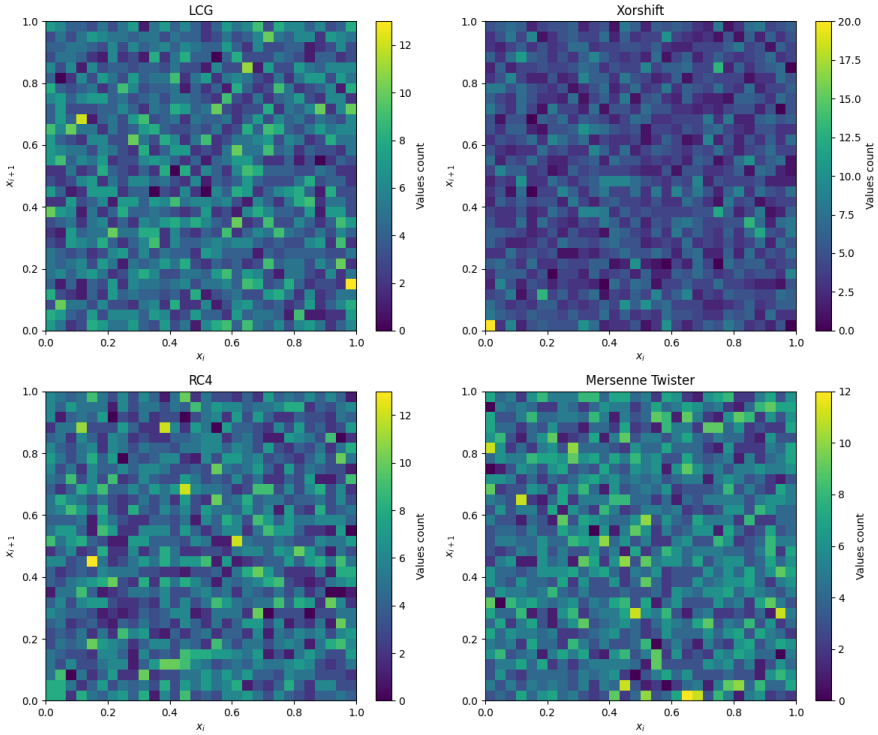

Rysunek 3: Mapy cieplne dla $n = 2^{12}$

Na powyższych mapach ciepła zobrazowano dwuwymiarowy rozkład kolejnych wartości (x_i, x_{i+1}) wygenerowanych przez różne generatory. Przedział jednostkowy $[0,1]^2$ został podzielony na $k \times k = 30 \times 30$ komórek, a następnie zliczono liczbę par wartości, które wpadły do każdej. Kolor odpowiada częstości występowania. Ciemniejsze pola oznaczają mniejszą liczbę punktów, a jaśniejsze większą.

Dla wszystkich czterech generatorów rozkład punktów jest w przybliżeniu jednorodny, bez widocznych struktur geometrycznych czy regularnych wzorców. Oznacza to, że kolejne wartości są w dużej mierze nieskorelowane.

W przypadku Xorshift128 widoczny jest jaśniejszy kwadrat w okolicach $(0,0)$ nie jest zjawiskiem niepożądanym. Generator ten może w pierwszych iteracjach produkować kilka wartości bliskich zeru ze względu na sposób aktualizacji bitów w rejestrze przesuwającym. Zjawisko to nie wpływa znacząco na ogólną równomierność rozkładu, a przy większej liczbie próbek różnice te powiny ulegać zatarciu. Nie wskazuje to więc na systematyczne zaburzenie losowości, lecz raczej na lokalne fluktuacje wynikające z ograniczonego rozmiaru próbki ($n = 2^{12}$).

LCG również prezentuje poprawny rozkład. Rozkład punktów jest równomierny, bez zauważalnych struktur, co prawdopodobnie wynika z dobrze dobranych parametrów - duży okres oraz iloczyn a.

Mersenne Twister natomiast prezentuje rozkład bardzo podobny do LCG – w miarę równomierny i pozbawiony wzorców, co potwierdza jego wysoką jakość oraz dużą przestrzeń stanów, minimalizującą ryzyko powtarzalności sekwencji. Miejscami widoczne są małe skupiska punktów, jednak można to zrzucić na małe $n = 2^{12}$ oraz "pechowe"ziarno.

W przypadku RC4 również widać równomierny rozkład, jednak nieco bardziej „ziarnisty”. Może to wynikać z tego, że tablica permutacji S (256 elementów) po inicjalizacji nie jest wystarczająco zrandomizowana - kolejne wartości są silnie skorelowane z początkowym stanem klucza.

Podsumowując, analiza dwuwymiarowych map ciepła potwierdza, że wszystkie badane generatory wytwarzają w przybliżeniu w miarę niezależne i równomiernie rozłożone próbki.

Spójrzmy teraz na mapy ciepła dla $n = 5 * 10^4$.

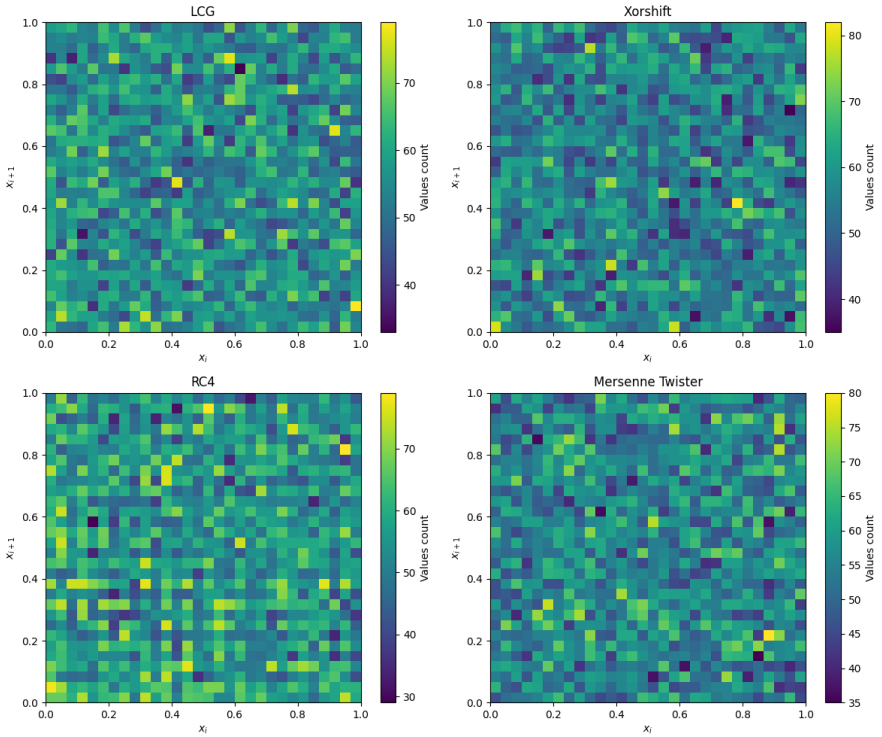

Rysunek 4: Mapy cieplne dla $n = 5 * 10^4$

Na pierwszy rzut oka na podstawie map cieplnych kolejnych liczb losowych (x_i, x_{i+1}) wygenerowanych przez cztery PRNG można stwierdzić, że wszystkie generatory wykazują w przybliżeniu równomierny rozkład w zakresie $[0,1]^2$, co wskazuje na brak silnej korelacji między kolejnymi wartościami.

Wyniki wskazują, że LCG charakteryzuje się równomiernym rozkładem wartości bez widocznych

wzorców, co świadczy o przyzwoitej jakości losowości przy tej liczbie próbek. Ponownie tak dobry wynik tego generatora można usprawiedliwić doborem dobrych parametrów, które zagwarantowały bardzo długi okres i brak powtarzalności sekwencji. Podobnie jak LCG, Xorshift również generuje dane o bardzo równomiernym rozkładzie, z nieznacznie większym rozrzutem liczności - to typowe dla tego typu generatora, który opiera się na prostych operacjach bitowych, zapewniając szybkie i stosunkowo dobre statystycznie wyniki. Najsłabiej wypadł generator RC4 - widoczne są nieregularności i lokalne zagęszczenia, co oznacza mniej równomierny rozkład i możliwe korelacje między kolejnymi wartościami. Ponownie może to wynikać z tego, że tablica permutacji S (256 elementów) po inicjalizacji nie jest wystarczająco zrandomizowana,a więc kolejne wartości są silnie skorelowane z początkowym stanem klucza. Mersenne Twister natomiast prezentuje rozkład bardzo podobny do Xorshift. zJest on równomierny i pozbawiony wzorców, co potwierdza jego wysoką jakość oraz dużą przestrzeń stanów, minimalizującą ryzyko powtarzalności ciągów.

9 Second-level testing

Second-level testing jest procedurą statystyczną, w której dany ciąg warości dzielony jest na mniejsze podokresy i dla każdego z nich przeprowadza się indywidualne testy. Dla każdego podokresu obliczana jest statystyka testowa oraz odpowiadająca jej p-wartość. Następnie zbiór p-wartości ze wszystkich podzbiorów można następnie analizować w celu oceny ich ogólnego zachowania, na przykład poprzez sprawdzenie, czy są one rozłożone jednostajnie zgodnie z hipotezą zerową.

W celu oceny jakości generatorów liczb pseudolosowych przeprowadzono procedurę second-level testing dla wcześniej badanych generatorów. Dla każdego generatora wygenerowano ciąg $n = 50{,}000$ liczb losowych, który następnie podzielono na 500 mniejszych podciągów. W każdym bloku zastosowano test χ^2 pierwszego poziomu z 10 przedziałami, aby sprawdzić, czy wartości w danym bloku mają rozkład jednostajny, co pozwoliło uzyskać 500 odpowiadających im p-wartości. Następnie te wartości zostały poddane testowi χ^2 drugiego poziomu, również z 10 przedziałami, w celu weryfikacji, czy same są rozłożone jednostajnie — czego byśmy oczekiwali, gdyby generator rzeczywiście produkował sekwencje o charakterze losowym. Procedura ta pozwala wykryć potencjalne nielosowe wzorce w poszczególnych fragmentach ciągu oraz porównać ogólną jakość statystyczną różnych generatorów.

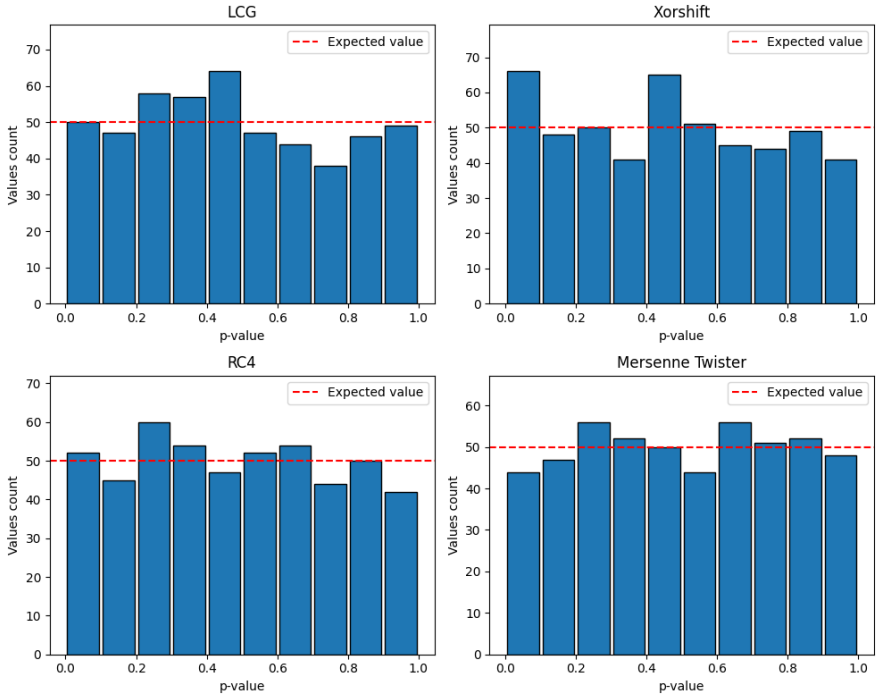

Rysunek 5: Porównanie rozkładów p-wartości

Przedstawione histogramy pokazują rozkłady p-wartości testu pierwszego poziomu dla każdego

generatora, przy czym czerwona linia przerywana wskazuje oczekiwaną liczbę wartości w każdym przedziale dla idealnego rozkładu jednostajnego. Spośród analizowanych generatorów, Mersenne Twister wykazał najbardziej równomierny rozkład p-wartości, potwierdzając swoje dobre właściwości statystyczne. RC4 również osiągnął dobre wyniki, wykazując jedynie niewielkie odchylenia od czerwonej prostej. Z kolei generatory LCG oraz Xorshift wykazały już bardziej zauważalne nieregularności w rozkładzie p-wartości. Szczególnie Xorshift wykazał tendencję do niższych p-wartości, których duża ilość została zakumulowana blisko 0, a tym samym słabszej jednorodności. Generator ten może w pierwszych iteracjach produkować kilka wartości bliskich zeru ze względu na sposób aktualizacji bitów w rejestrze przesuwającym. Ogólnie rzecz biorąc, test χ^2 drugiego poziomu skutecznie ujawnił subtelne różnice w jakości działania generatorów, które mogłyby pozostać niezauważone przy analizie jednopoziomowej, potwierdzając jego przydatność jako metody oceny losowości wyższego rzędu.

Aby zweryfikować wstępne wnioski, dla każdego generatora obliczono p-wartość.

Tabela 3: p-wartości drugiego poziomu oraz średnie pierwszego poziomu dla testowanych PRNG.

Generator	**p-wartości drugiego poziomu**	**Średnie p-wartości pierwszego poziomu**
LCG	0.313	0.482
Xorshift	0.115	0.478
RC4	0.791	0.489
Mersenne Twister	0.950	0.510

Wyniki przedstawione w tabeli podsumowują rezultaty testów χ^2 drugiego poziomu oraz średnie p-wartości pierwszego poziomu dla wszystkich analizowanych PRNG. Wartość p drugiego poziomu odzwierciedla stopień jednorodności rozkładu wartości p uzyskanych na poziomie pierwszym. Przyjęto poziom istotności $\alpha = 0.05$. Generator Mersenne Twister osiągnął najwyższą p-wartość drugiego poziomu oraz p-wartość pierwszego poziomu równą 0,510, co potwierdza wysoką jednorodność i niezależność generowanego ciągu. Generator RC4 również wykazał bardzo dobre właściwości, uzyskując p-wartość drugiego poziomu równą 0,791, co wskazuje na jednostajny rozkład generowanych liczb. Dla porównania, generatory LCG oraz Xorshift uzyskały niższe wartości p drugiego poziomu, co sugeruje odchylenia od idealnej jednorodności. W przeprowadzonych testach widać, że wszystkie badane generatory uzyskały bardzo zbliżone średnie p-wartości z testów pierwszego poziomu. Oznacza to, że na poziomie pojedynczych testów statystycznych ich zachowanie było porównywalne, a różnice w losowości nie ujawniają się wprost w średnich p-wartościach. Dopiero analiza drugiego poziomu pozwoliła na wykrycie subtelnych różnic jakościowych pomiędzy generatorami.

10 Podsumowanie wyników

Przeprowadzona analiza porównawcza LCG, RC4, Xorshift128 oraz Mersenne Twister pozwoliła ocenić ich własności statystyczne z wykorzystaniem zarówno testów pierwszego, jak i drugiego poziomu.

Mersenne Twister uzyskał jedne z lepszych wyników we wszystkich testach statystycznych. Cechuje się bardzo długim okresem, wysoką równomiernością rozkładu oraz stabilnością p-wartości w analizie drugiego poziomu. Jest najbardziej rekomendowanym generatorem do symulacji i obliczeń naukowych.

Xorshift128 wykazuje bardzo dobre właściwości przy niewielkich kosztach obliczeniowych, co czyni go dobrym kompromisem między szybkością a jakością losowości. Jego słabsze wyniki w testach typu Birthday Spacing oraz second-level sugerują jednak, że może nie być optymalny dla symulacji wymagających wysokiej precyzji statystycznej.

LCG mimo swojej prostoty uzyskał dobre wyniki, prawdopodobnie przez dobrze dobrane parametry, zwłaszcza w testach jednowymiarowych. Jednak ze względu na liniowy charakter i potencjalne korelacje w przestrzeniach wielowymiarowych nie powinien być stosowany w zaawansowanych symulacjach.

RC4 wypadł dobrze w większości testów, lecz wykazał słabość w Monobit Test, co potwierdza znany problem biasu w jego początkowych stanach. Pomimo dobrych wyników wizualnych, nie jest zalecany do zastosowań wymagających wysokiej jakości statystycznej.

Podsumowując, z przeprowadzonych badań wynika, że Mersenne Twister jest najbardziej losowym i statystycznie stabilnym generatorem z analizowanych, natomiast Xorshift128 stanowi dobrą alternatywę w sytuacjach, gdzie kluczowe znaczenie ma szybkość generowania liczb przy akceptowalnym poziomie jakości losowości.